



UNIVERSIDADE FEDERAL DO CEARÁ - CAMPUS CRATEÚS
CIÊNCIA DA COMPUTAÇÃO E SISTEMAS DE INFORMAÇÃO
CIÊNCIA DOS DADOS 2025.2

ANÁLISE EXPLORATÓRIA E VISUALIZAÇÃO DE DADOS

DISCENTES

FRANCISCO DIEGO TARGINO SABINO - 538289

MARIA CLARA PEREIRA DE SOUSA - 536940

DOCENTE

PROF. DR. RENAN GOMES VIEIRA

CRATEÚS 2025

SUMÁRIO

Introdução	3
Dados Utilizados	3
Procedimentos Realizados	4
Dificuldades Encontradas	9

Introdução

Este relatório apresenta uma análise exploratória e a visualização inicial do conjunto de dados selecionado para o trabalho. A etapa de Análise Exploratória de Dados (AED) tem como finalidade oferecer uma primeira compreensão sobre o dataset, identificando características, padrões gerais, limitações e possíveis problemas que podem impactar nas etapas seguintes da análise.

Durante a elaboração do trabalho, foi possível compreender a composição dos dados, investigar relações entre atributos, detectar inconsistências, outliers e valores faltantes, além de produzir visualizações que auxiliem na interpretação dos dados disponíveis. A partir disso, foi feito pré-processamento específico para cada dataset e um levantamento de hipóteses relevantes.

Dados Utilizados

Neste trabalho foram selecionados três conjuntos de dados distintos, cada um proveniente de fontes diferentes e com finalidades próprias.

0.1 Índice Brasileiro de Conectividade (IBC)

O dataset do **Índice Brasileiro de Conectividade (IBC)**, disponibilizado pelo Governo Federal por meio do portal de dados abertos (*dados.gov.br*), apresenta indicadores relacionados ao nível de conectividade dos municípios brasileiros, calculados e divulgados pela Anatel.

O IBC é composto por sete indicadores que avaliam a infraestrutura de telecomunicações de cada município. Entre eles estão a densidade de acessos móveis (quantidade de chips por habitante), a densidade de banda larga fixa (assinaturas de internet por habitante), a cobertura populacional por telefonia móvel (percentual da população atendida) e o adensamento de estações rádio base (quantidade de antenas disponíveis). Por meio desse conjunto de dados é possível medir o nível de conectividade de cada região e identificar desigualdades no acesso à internet e aos serviços de comunicação, apoiando decisões de políticas públicas e investimentos tecnológico.

0.2 Diabetes Dataset

O dataset **Diabetes Dataset**, disponibilizado na plataforma Kaggle contém informações clínicas de pacientes e é amplamente utilizado em estudos de aprendizado de máquina voltados

à predição de diabetes.

Entre as variáveis disponíveis destacam-se: número de gestações, níveis de glicose no plasma, pressão arterial, espessura da pele, níveis de insulina, índice de massa corporal (IMC), função de histórico familiar de diabetes e idade. A variável alvo indica se o paciente apresenta ou não diabetes.

0.3 scRNA-seq Cancer Microenvironment Classification

O dataset **scRNA-seq Cancer Microenvironment Classification**, também disponível no Kaggle, contém dados de expressão gênica em nível de célula única (*single-cell RNA sequencing*), representando células presentes no microambiente tumoral.

Cada instância corresponde a uma célula, com atributos que representam níveis de expressão gênica ou métricas derivadas, além de um rótulo que classifica o tipo celular. Esse tipo de dado é extremamente relevante em estudos de heterogeneidade tumoral, identificação de subpopulações celulares e investigação de vias biológicas associadas ao câncer.

Procedimentos Realizados

0.4 Diabetes Dataset

O dataset utilizado neste estudo contém informações sobre indicadores de diabetes em 768 pacientes, com 9 atributos clínicos. Inicialmente, foram importadas as bibliotecas essenciais para análise de dados (`pandas`, `numpy`, `matplotlib`, `seaborn`) e realizada a carga do arquivo `diabetes_dataset.csv`.

A exploração inicial revelou uma estrutura completa sem valores nulos, porém uma análise mais detalhada identificou a presença de valores zero em variáveis onde tal valor é biologicamente impossível.

0.4.1 Identificação e Tratamento de Dados Inconsistentes

Foram detectados valores zero inconsistentes nas seguintes variáveis críticas:

- **Glucose:** 5 valores (0.65% do total)

- **BloodPressure:** 35 valores (4.56% do total)
- **Insulin:** 374 valores (48.70% do total)
- **BMI:** 11 valores (1.43% do total)

Considerando a impossibilidade biológica de valores zero nestas medições, optou-se pela remoção das linhas contendo tais inconsistências. Esta etapa reduziu o dataset de 768 para 392 entradas, representando uma redução de 49% dos dados originais.

0.4.2 Tratamento de Outliers

Para garantir a robustez das análises subsequentes, foi implementada uma estratégia de detecção e remoção de outliers baseada no cálculo do Z-score. O critério adotado considerou como outliers os valores com Z-score absoluto maior que 3 em todas as variáveis numéricas.

Esta etapa resultou na remoção de 27 registros adicionais, totalizando 365 entradas no dataset final. A Tabela 1 resume o impacto do pré-processamento no volume de dados.

Tabela 1: Impacto do Pré-processamento no Volume de Dados

Etapas do Processamento	Nº de Entradas	Redução
Dataset Original	768	-
Após Remoção de Zeros Inválidos	392	49.0%
Dataset Final (sem outliers)	365	52.5%

0.5 Dataset IBC Municípios

0.5.1 Carregamento e Exploração Inicial

O dataset utilizado neste estudo contém indicadores do Índice Brasileiro de Conectividade (IBC) para municípios brasileiros, abrangendo 22.280 entradas com 13 atributos principais. Inicialmente, foram importadas as bibliotecas essenciais para análise de dados (pandas, numpy, matplotlib, seaborn) e realizada a carga do arquivo `IBC_municipios_indicadores_normalizados.csv`.

A exploração inicial revelou dados de múltiplos anos (2021-2024) com cobertura nacional, porém uma análise mais detalhada identificou a presença significativa de valores ausentes em uma variável crítica.

0.5.2 Identificação e Tratamento de Dados Ausentes

Foram detectados valores ausentes na seguinte variável estratégica:

- **Cobertura da Área Agricultável:** 16.723 valores (75,07% do total)

Considerando a importância deste indicador para análises de conectividade rural, optou-se pela imputação utilizando a mediana da variável. Esta abordagem preservou a integridade do dataset mantendo todas as 22.280 entradas originais.

0.5.3 Padronização de Dados Numéricos

Identificou-se que as colunas numéricas utilizavam vírgula como separador decimal, incompatível com operações matemáticas. Realizou-se:

- Conversão sistemática de todas as variáveis numéricas para formato decimal padrão
- Substituição de vírgulas por pontos em 9 colunas numéricas principais
- Conversão final para tipo float para permitir análises estatísticas

0.5.4 Análise Estatística Descritiva

Após o pré-processamento, foi realizada análise estatística completa que revelou:

- Período coberto: 2021-2024 (dados anuais)
- Amplitude geográfica: 5.570 municípios únicos, abrangendo as 27 UFs

A Tabela 2 resume o impacto do pré-processamento no dataset.

Tabela 2: Impacto do Pré-processamento no Dataset IBC Municípios

Etapas do Processamento	Nº de Entradas	Preservação
Dataset Original	22.280	-
Após Tratamento de Valores Ausentes	22.280	100%
Dataset Final (padronizado)	22.280	100%

0.6 Dataset scRNA-seq: Classificação do Microambiente do Câncer

0.6.1 Carregamento e Exploração Inicial

O dataset utilizado neste estudo contém dados de sequenciamento de RNA de célula única (scRNA-seq) para classificação do microambiente tumoral (TME), composto por 3.000 amostras celulares com 10 atributos principais. Inicialmente, foram importadas as bibliotecas essenciais para análise de dados (`pandas`, `numpy`, `matplotlib`, `seaborn`, `scipy.stats`) e realizada a carga do arquivo `scRNA-seq.csv`.

A exploração inicial revelou dados de expressão gênica de múltiplos tipos celulares, com cobertura balanceada entre condições tumorais e saudáveis. A análise da estrutura dos dados identificou um dataset completo sem valores ausentes.

0.6.2 Estrutura e Composição dos Dados

O dataset apresenta a seguinte composição:

- **Total de Amostras:** 3.000 células únicas
- **Atributos:** 10 colunas (3 categóricas, 7 numéricas)
- **Identificadores:** `Cell_ID` como identificador único para cada célula

Os principais atributos incluem:

- **Variáveis Categóricas:** Tipo celular (`Cell_Type`) e status da doença (`Disease_Status`)
- **Variáveis Numéricas:** Expressão gênica específica (`Gene_A_Oncogene`, `Gene_B_Immune`, etc.) e coordenadas de redução dimensional (`UMAP_1`)

0.6.3 Análise de Qualidade e Integridade dos Dados

A verificação da qualidade dos dados revelou:

- **Valores Ausentes:** Nenhum valor NaN ou NULL detectado em todo o dataset
- **Balanceamento:** Distribuição equilibrada de tipos celulares (1.000 amostras cada)

0.6.4 Análise Estatística Descritiva

A análise estatística detalhada revelou características importantes das variáveis numéricas:

- **Expressão Gênica:** Variação significativa entre diferentes genes, com `Gene_A_Oncogene` apresentando maior variabilidade ($DP = 4,96$)
- **Gene Housekeeping:** Menor variabilidade ($DP = 0,50$), conforme esperado para genes de manutenção celular
- `Pathway_Score_Inflam`: Atividade inflamatória variando entre 1,0 e 17,99, indicando diversidade na resposta imune

A distribuição de `Disease_Status` mostrou predominância de amostras tumorais (2.595) sobre controles saudáveis (405), refletindo o foco em oncologia.

0.6.5 Próximas Etapas

O dataset encontra-se preparado para análises exploratórias avançadas, incluindo:

- Análise de expressão diferencial entre tipos celulares
- Visualização de clusters via redução dimensional (UMAP)
- Correlações entre vias biológicas e marcadores gênicos
- Modelagem preditiva para classificação de tipo celular
- Identificação de assinaturas genéticas associadas à resposta terapêutica

0.6.6 Considerações para Análises Futuras

- Investigar a natureza dos valores em `UMAP_1` para confirmar validade
- Considerar técnicas específicas para dados desbalanceados em `Disease_Status`
- Explorar interações entre oncogenes e resposta imune no microambiente tumoral
- Validar potenciais biomarcadores através de análise de expressão diferencial

Tabela 3: Resumo do Dataset scRNA-seq após Pré-processamento

Característica	Valor	Observações
Amostras totais	3.000	100% preservadas
Valores ausentes	0	Dataset completo
Tipos celulares	3	Balanceados
Condições	2	Tumor vs. Saudável
Variáveis numéricas	7	Expressão gênica + UMAP

Dificuldades e Desafios no Processo de Análise

Dentre as dificuldades encontradas se destaca a seleção de bases de dados boas para serem trabalhadas, a melhor maneira de representar as perguntas através de visualização de dados e como tratar os dados ausentes.